

Chapitre III : Estimation, spécification et prévision d'un **modèle ARMA**

Yannick Le Pen

- 1 Introduction
- 2 Estimation
- 3 Les tests de validation
- 4 Prévision
- 5 Critères de comparaison de modèles


- Utilisation d'un modèle ARMA pour modéliser une série économique.
- Conditions d'application :
- Une série stationnaire
- cette série présente de l'autocorrélation ou de l'autocorrélation partielle.
- Dans le cas d'une série stationnaire sans autocorrélation ni autocorrélation partielle, il n'y a pas à chercher de représentation par un modèle ARMA.

Introduction : étapes de la procédure d'estimation

- Détermination du nombre de retards p et q à l'aide de l'autocorrélogramme de la série
- Estimation du modèle
- Tests de validation du modèle :
 - 1 test de significativité des coefficients et analyse des racines
 - 2 test sur les résidus
- Recherche d'un modèle alternatif si les conditions de validité du modèle estimé ne sont pas satisfaites.
- Prévision à l'aide d'un modèle ARMA

Exemple de l'indice S&P 500

- Indice S&P 500 pas stationnaire mais son taux de rendement stationnaire
- Modélisation du taux de rendement du S&P 500
- Autocorrélogramme du taux de rendement



- Autocorrélations (et les autocorrélations partielles) significatives aux ordres 1 et 2

- On veut estimer un modèle $\text{ARMA}(p,q)$:

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \epsilon_t + \sum_{i=1}^q \theta_i \epsilon_{t-i}$$

- Echantillon de T observations $\{x_1, x_2, \dots, x_T\}$
- Les paramètres inconnus sont :
 - les nombres de retards p (composante AR) et q (composante MA)
 - la constance c
 - les p paramètres $\phi_1, \phi_2, \dots, \phi_p$ de la partie AR
 - les q paramètres $\theta_1, \theta_2, \dots, \theta_q$ de la partie MA
 - la variance σ_ϵ^2 du terme d'erreur ϵ_t .
- soit au final $1 + 1 + 1 + p + q + 1$ paramètres inconnus.

- Méthode d'estimation : estimateur du maximum de vraisemblance.
- Il n'existe pas de solution analytique et l'estimation des paramètres se fait par des méthodes de résolution numérique.
- Sous des conditions assez générales, cet estimateur suit une loi normale, ce qui implique que les tests statistiques standards sur les coefficients peuvent être appliqués.
- Dans le cas d'un processus $AR(p)$ sans composante MA, l'estimateur du maximum de vraisemblance correspond à l'estimateur des MCO.

- Exemple du taux de rendement de l'indice S&P 500
- Autocorrélation et l'autocorrélation partielle jusqu'à l'ordre 2 pour r_{SP500}
- Ni à un modèle AR, ni à un modèle MA purs
- On commence par un ARMA(2,2).

gretl: modèle 2

Evaluations de la fonction : 47
 Evaluations du gradient : 10


Modèle 2: ARMA, utilisant les observations 2007-01-04:2017-07-14 (T = 2651)
 Estimé à l'aide du filtre de Kalman (MV exacte)
 Variable dépendante: d_1_SP500
 Écarts type basés sur la matrice hessienne

	coefficient	erreur std.	z	p. critique	
const	0,000207988	0,000220019	0,9453	0,3445	
phi_1	-0,4302000	0,179485	-2,397	0,0165	**
phi_2	-0,3002001	0,169577	-1,770	0,0767	*
theta_1	0,323598	0,183486	1,764	0,0777	*
theta_2	0,208562	0,176070	1,185	0,2362	
Moy. var. dép.	0,000208				
Éc. type var. dép.	0,012901				
Moyenne des innovations	-4,11e-08				
Éc. type des innovations	0,012794				
Log de vraisemblance	7793,602				
Critère d'Akaike	-15575,20				
Critère de Schwarz	-15539,91				
Hannan-Quinn	-15562,43				

	Réel	Imaginaire	Modulo	Fréquence
AR				
Racine 1	-0,7165	-1,6786	1,8251	-0,3142
Racine 2	-0,7165	1,6786	1,8251	0,3142
MA				
Racine 1	-0,7758	-2,0477	2,1897	-0,3076
Racine 2	-0,7758	2,0477	2,1897	0,3076

- Vérifier si le modèle estimé est conforme au modèle théorique d'un processus ARMA
- Test 1 : Analyse des racines
 - Vérifier que les racines de la partie AR sont de module strictement supérieur à 1
 - Si oui : la série modélisée est bien stationnaire
 - Si non : la série modélisée n'est pas stationnaire
- Exemple du taux de rendement du S&P 500
- le module des deux racines est égal à 1,8251
- taux de rendement est stationnaire

Test de Student des paramètres

- On vérifie la significativité des paramètres estimés avec la statistique de Student. 
- En particulier, les coefficients des derniers retards doivent être significativement différents de 0, sinon, ils doivent être éliminés.
- Exemple du taux de rendement du S&P 500
 - la constante c n'est pas significative
 - le coefficient ϕ_1 est significatif à 5%
 - les coefficients ϕ_2 et θ_1 sont significatifs à 10%
 - le coefficient θ_2 n'est pas significatif
 - Ce modèle ARMA(2,2) n'est pas valide. On doit estimer un modèle avec moins de retards pour la partie MA.

- Après élimination du deuxième puis du premier retard de la composante MA, on estime le modèle AR(2) :

Evaluations de la fonction : 43
Evaluations du gradient : 6

Modèle 10: ARMA, utilisant les observations 2007-01-04:2017-07-14 (T = 2681)
Estimé à l'aide du filtre de Kalman (MV exacte)
Variable dépendante: d_1_SPS00
Écarts type basés sur la matrice hessienne

	coefficient	erreur std.	z	p. critique
const	0,000207862	0,000210352	0,9849	0,3247
phi_1	-0,111405	0,0193659	-5,753	6,79e-09 ***
phi_2	-0,0665268	0,0193200	-3,443	0,0006 ***

Moy. var. dép. 0,000208
Éc. type var. dép. 0,012901
Moyenne des innovations -9,29e-08
Éc. type des innovations 0,012799
Log de vraisemblance 7792,442
Critère d'Akaike -15576,88
Critère de Schwarz -15553,35
Hannan-Quinn -15568,37

	Réal	Imaginaire	Module	Fréquence
AR				
Racine 1	-0,8373	-3,7856	3,8771	-0,2846
Racine 2	-0,8373	3,7856	3,8771	0,2846

- ϕ_1 et ϕ_2 significatifs
- Racines de la partie AR sont de module supérieur à 1.

- Dans le modèle théorique, $\epsilon_t \sim BB(0, \sigma_\epsilon^2)$.
- Vérification que les résidus $\hat{\epsilon}_t$ se comportent comme un bruit blanc.
 - ① tests de Ljung-Box d'absence d'autocorrélation
 - ② tests d'homoscédasticité : test d'un effet ARCH
 - ③ test de l'hypothèse de normalité des résidus : test de Jarque et Bera


Tests de Ljung-Box d'absence d'autocorrélation des résidus

- On teste l'hypothèse d'absence d'autocorrélation des résidus jusqu'au rang k :

$$\begin{cases} H_0 : \rho_1 = \rho_2 = \dots = \rho_k = 0 \\ H_1 : \exists i \in \{1, 2, \dots, k\} \text{ t.q. } \rho_i \neq 0 \end{cases}$$

- ρ_i est l'autocorrélation des résidus \hat{e}_t .
- La statistique de test est $Q_k^* = T(T+2) \sum_{j=1}^k \frac{1}{T-j} \hat{\rho}_j^2$
- Sous H_0 , $Q_k^* \rightarrow \chi^2(k-p-q)$
- On rejette H_0 si la statistique de test est supérieure au seuil critique choisi, ou si la probabilité critique est inférieure au risque de première espèce.
- Si l'on rejette H_0 , on doit estimer un nouveau modèle, en augmentant le nombre de retards pour la partie AR ou la partie MA.

Test de Ljung-Box appliqué au taux de rendement du S&P 500



- On voit que l'on accepte l'hypothèse nulle d'absence d'autocorrélation (de peu) pour un risque de première espèce de 1%.
- On rejette cette hypothèse pour un risque de 5% et 10%
- le modèle estimé passe (de peu) les critères de validation.

Test de l'hypothèse de normalité de Jarque et Bera

- On veut vérifier si les résidus $\hat{\epsilon}_t$ suivent une loi normale. Ce test est basé sur :
 - le skewness S : le coefficient d'asymétrie d'une distribution,
 - le kurtosis K : le coefficient d'aplatissement.

Test de Jarque et Bera : Interprétation du Skewness

- Le skewness mesure le degré d'asymétrie d'une distribution
- L'expression du Skewness est $S(X) = \frac{E(X-E(X))^3}{\sigma(X)^3}$
- Si $S = 0$, la distribution est symétrique autour de sa moyenne
- Si $S > 0$, la distribution est étalée vers la droite
- Si $S < 0$, la distribution est étalée vers la gauche.
- Si $X \sim N(0,1)$, la distribution de X est symétrique autour de 0 et $S(X) = 0$ et $K(X) = 3$ ¹.

1. On définit aussi l'excès de kurtosis comme $K(X) - 3$.

Test de Jarque et Bera : interprétation du kurtosis

- Le kurtosis mesure le degré d'aplatissement d'une distribution.
- L'expression du kurtosis est $K(X) = \frac{E(X-E(X))^4}{\sigma(X)^4}$
- Il est lié à la probabilité d'apparition des valeurs extrêmes
- Si $X \sim N(0, 1)$, $K(X) = 3$.
- On définit aussi l'excès de kurtosis comme $K(X) - 3$.
- Si pour une variable Y , on a $K(Y) > 3$ alors la probabilité d'apparition de valeurs extrêmes pour Y est plus importante que dans le cas d'une loi normale.

Test de Jarque et Bera : Estimation de $S(X)$ et $K(X)$

Le skewness et le kurtosis sont estimés par :

$$\hat{S}(X) = \frac{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^3}{\left[\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2 \right]^{3/2}}$$
$$\hat{K}(X) = \frac{\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^4}{\left[\frac{1}{T} \sum_{t=1}^T (x_t - \bar{x})^2 \right]^2}$$

Test de Jarque et Bera

- fondé sur la comparaison entre le skewness et le kurtosis estimé à partir d'un échantillon et les valeurs de référence de la loi normale.
- Hypothèses du test :

$$\begin{cases} H_0 : S(X) = 0 \text{ et } K(X) = 3 \\ H_1 : S(X) \neq 0 \text{ ou } K(X) \neq 3 \end{cases}$$

- La statistique du test notée LJB est une moyenne pondérée de $(S(X) - 0)^2$ et $(K(X) - 3)^2$.
- Sous H_0 , la statistique de test suit la loi $LJB \rightarrow \chi^2(2)$.
- On rejettera H_0 si la statistique de test est supérieure au seuil critique ou si la probabilité critique est inférieure au risque de première espèce choisi.

Application au taux de rendement du S&P 500

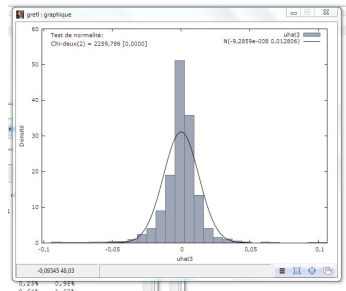
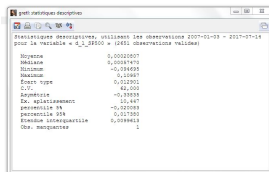


Figure – Résultat du test de normalité de Jarque et Bera

- La valeur de la statistique de test "chi-deux = 2257,786"
- La probabilité critique égale à 0.
- On rejette donc l'hypothèse de normalité des résidus.

Application au taux de rendement du S&P 500




Statistiques descriptives, utilisant les observations 2007-01-03 - 2017-07-14 pour la variable « d_s_5P500 » (2451 observations valides)	
Moyenne	0,00020007
Médiane	0,00047470
Minimum	-0,094695
Maximum	0,10967
Kurtosis	0,012001
C.V.	42,000
Asymétrie	-0,33835
Ex. aplatissement	10,447
percentile 1%	-0,020003
percentile 99%	0,057500
Ecart interquartile	0,008668
Obs. manquantes	1

- $S = -0,33835$. La distribution du taux de rendement est légèrement étalée vers la gauche.
- La probabilité de rendements négatifs est plus élevée que celle de rendements positifs
- $K - 3 = 10,447$.
- Probabilité d'apparition de rendements extrêmes est plus importante que dans le cas d'une loi normale.

Test d'un effet ARCH


- On veut vérifier si la variance du résidu $\hat{\epsilon}_t$ ne dépend pas du temps.
- Une caractéristique des séries financières.



- Alternance de période de fortes et faibles fluctuations (alternance de "boom and bust".)
- On parle aussi de cluster de volatilité

Test d'un effet ARCH

- On utilise $\hat{\epsilon}_t^2$ comme une proxy de la volatilité :



- Alternance de périodes **tranquilles** et de périodes de forte **volatilité**.

Test d'un effet ARCH

- Le test d'un effet ARCH est fondé sur l'estimation de la régression :

$$\hat{\epsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\epsilon}_{t-1}^2 + \dots + \alpha_q \hat{\epsilon}_{t-q}^2 + u_t$$

- Hypothèses du test :

$$\begin{cases} H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_q = 0 \Rightarrow \text{pas d'effet ARCH} \\ H_a : \alpha_1 \neq 0 \text{ ou } \alpha_2 \neq 0 \dots \text{ ou } \alpha_q \neq 0 \Rightarrow \text{effet ARCH} \end{cases}$$

Statistique de test est :

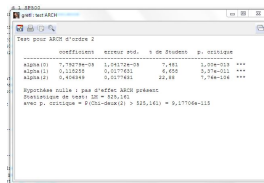
$$LM_{stat} = TR^2 \rightarrow \chi^2(q)$$

où T est le nombre d'observations et R^2 le R^2 de la régression de $\hat{\epsilon}_t^2$ sur les $\{\hat{\epsilon}_{t-i}^2\}$.

- Le test d'un effet ARCH est le plus souvent appliqué à des séries de

Test d'un effet ARCH sur le taux de rendement du S&P 500

- On applique le test d'un effet ARCH avec 2 retards au taux de rendement du S&P 500.



```
Test pour ARCH d'ordre 2

-----
coefficients  erreur std.  t de Student  p. critique
-----
alpha(0)  7.79278e+08  1.04172e+08  7.481  1.05e-153 ***
alpha(1)  0.112285  0.0177621  6.325  5.37e-111 ***
alpha(2)  0.406249  0.0177621  22.88  7.79e-124 ***

Hypothèse nulle : pas d'effet ARCH présent
Statistique de test: LM = 325.161
avec p. critique = F(2,4)=den(2) > 325.161 = 9.17706e-115
```


- Probabilité critique égale à 0 : rejet l'hypothèse d'absence d'effet ARCH.

Remarques sur les tests sur les résidus

On accorde pas la même importance à tous les tests sur les résidus.

- 1 Le test d'absence d'autocorrélation doit être validé. Si ce n'est pas le cas, il faut chercher un modèle ARMA alternatif
- 2 Si on rejette l'hypothèse de loi normale, on ne fait rien de plus
- 3 Si on rejette l'hypothèse d'absence d'effet ARCH, on pourra estimer un modèle de volatilité conditionnelle (voir le chapitre sur la modélisation GARCH).

- Le modèle **AR(2)** a passé les tests de validation
- Faible différence entre l' écart type des résidus (innovation) et celui de la variable dépendante est petite.
- Faible pouvoir explicatif du modèle (assez attendu pour une série financière).
- Conclusion confirmée par le graphique des valeurs observées et des valeurs ajustées :



- Utilisation du modèle validé pour faire de la prévision (à court terme).
- Informations nécessaires pour faire une prévision sont :
 - ① un modèle de génération des données : la modèle que l'on a estimé et validé.
 - ② les valeurs passées de x_t à la date t : $I_t = \{x_s, s \leq t\}$
 - ③ la date t à laquelle la prévision est faite
 - ④ le nombre de périodes dans le futur pour lesquelles la prévision est faite : l'horizon de la prévision h
- $x_t^a(h)$ = la valeur prévue en t de x_{t+h} .
- L'erreur de prévision est la différence entre la valeur observée et la valeur prévue $e_t(h) = x_{t+h} - x_t^a(h)$.
- Deux types de prévision :
 - ① la prévision ponctuelle
 - ② la prévision par intervalle de confiance

- On veut calculer des prévisions à la date t
- A cette date t , si l'on considère toutes les valeurs de x_{t+h} , on aura :
 - x_{t+h} connu si $h \leq 0$
 - x_{t+h} inconnu si $h > 0$ et remplacé par son prédicteur $x_t^a(h)$
- De la même façon, on aura :
 - ϵ_{t+h} connu si $h \leq 0$
 - ϵ_{t+h} inconnu si $\forall h > 0$ et remplacé par sa moyenne $E(\epsilon_t) = 0$
- On utilise ces formules pour calculer tous les prédicteurs.

Prévision ponctuelle dans le cas d'un $AR(1)$

- $AR(1)$ stationnaire $x_t = \phi_1 x_{t-1} + \epsilon_t$
- En t , on veut prévoir x_{t+1} : prévision à l'horizon $h=1$
- On a $x_{t+1} = \phi_1 x_t + \epsilon_{t+1}$
- En t , x_t est connu et ϵ_{t+1} est inconnu et remplacé par 0.
- La prévision en t de x_{t+1} est :

$$x_t^a(1) = \phi_1 x_t$$

- $x_t^a(1)$ est la valeur ajustée du modèle
- ϵ_{t+1} est la variation de x entre t et $t+1$ non prévisible à la date t .

Prévision ponctuelle dans le cas d'un $AR(1)$

- L'erreur de prévision à l'horizon $h=1$ est :

$$e_t(1) = x_{t+1} - x_t^a(1) = (\phi_1 x_t + \epsilon_{t+1}) - \phi_1 x_t = \epsilon_{t+1}$$

- L'erreur de prévision est nulle *en moyenne* :

$$E(e_t(1)) = E(\epsilon_{t+1}) = 0 \Rightarrow E(x_t^a(1)) = x_{t+1}$$

- Le prédicteur $x_t^a(1)$ est dit sans biais².
- La variance de l'erreur de prévision est $V(e_t(1)) = V(\epsilon_{t+1}) = \sigma_\epsilon^2$

² Sous réserve que le modèle $AR(1)$ soit le bon modèle.

Prévision à l'horizon $h=2$

- On applique les mêmes principes que précédemment
- $x_{t+2} = \phi_1 x_{t+1} + \epsilon_{t+1}$
- En t , x_{t+1} est inconnu et remplacé par son prédicteur $x_t^a(1) = \phi_1 x_t$
- En t , ϵ_{t+1} est inconnu et remplacé par son espérance $E(\epsilon_{t+1}) = 0$.
- En t , la prévision de x_{t+2} est donc :

$$x_t^a(2) = \phi_1 x_t^a(1) = \phi_1^2 x_t$$

Prévision à l'horizon $h=2$

- L'erreur de prévision à l'horizon $h=2$ est :

$$\begin{aligned}
 e_t(2) &= x_{t+2} - x_t^a(2) \\
 &= (\phi_1 x_{t+1} + \epsilon_{t+2}) - \phi_1 x_t^a(1) \\
 &= \phi_1 (x_{t+1} - x_t^a(1)) + \epsilon_{t+2} \\
 &= \phi_1 \epsilon_{t+1} + \epsilon_{t+2}
 \end{aligned}$$

- L'erreur de prévision est nulle en moyenne et le prédicteur $x_t^a(2)$ est sans biais : $E(e_t(2)) = 0 \Rightarrow E(x_t^a(2)) = x_{t+2}$
- La variance de l'erreur de prévision est $V(e_t(2)) = \sigma_\epsilon^2(1 + \phi_1^2)$
- L'erreur de prévision est nulle en moyenne mais sa variance augmente avec l'horizon de la prévision.

Généralisation à un **AR(p)**

- On en déduit que pour $h > 1$, on aura $x_t^a(h) = \phi_1 x_t^a(h-1) = \phi_1^h x_t$
- Les prévisions faites en t pour tous les horizons $h > 0$ se calculent à partir des paramètres du modèles et des variables observées jusqu'en t
- Dans le cas d'un **AR(1) stationnaire**, on a $|\phi_1| < 1$. On en déduit que $\lim_{h \rightarrow +\infty} x_t^a(h) = 0 = E(x_t)$. A mesure que l'horizon de la prévision augmente, la prévision converge vers l'espérance inconditionnelle de x_t .

Prévisions statiques et prévisions dynamiques

- $x_t^a(2) = \phi_1^2 x_t$ est une prévision *dynamique* : on a une date t fixe et l'on fait varier l'horizon de la prévision.
- Les prévisions dynamiques se calculent de façon récursive : pour $h = 1$, puis $h = 2$, puis $h = 3, \dots$
- Dans le cas de la prévision *statique*, l'horizon de la prévision est toujours $h = 1$. C'est la date t de la prévision qui varie :
 - $x_t^a(1) = \phi_1 x_t$ est la prévision statique de x_{t+1} .
 - $x_{t+1}^a(1) = \phi_1 x_t$ est la prévision **statique** de x_{t+2} .
- $x_t^a(1)$ est la valeur ajustée du modèle

Prévision à l'horizon $h=1$ dans le cas d'un $MA(1)$

- $x_t = \epsilon_t + \theta_1 \epsilon_{t-1}$
- le mode de calcul des prévisions se généralise à un processus $MA(q)$ quelconque
- En $t+1$, on a $x_{t+1} = \epsilon_{t+1} + \theta_1 \epsilon_t$
- En t , ϵ_t est connu
- En t , ϵ_{t+1} est inconnu et remplacé par son espérance $E(\epsilon_{t+1}) = 0$
- On en déduit la prévision en t de x_{t+1} :

$$x_t^a(1) = \theta_1 \epsilon_t$$

Prévision à l'horizon $h=1$ dans le cas d'un $MA(1)$

- L'erreur de prévision est :

$$e_t(1) = x_{t+1} - x_t^a(1) = (\epsilon_{t+1} + \theta_1 \epsilon_t) - \theta_1 \epsilon_t = \epsilon_{t+1} \Rightarrow E(e_t(1)) = 0$$

- L'erreur de prévision est nulle en moyenne, le prédicteur est sans biais.
- La variance de l'erreur de prévision est $V(e_t(1)) = V(\epsilon_{t+1}) = \sigma_\epsilon^2$

Prévision à l'horizon $h=2$

- En $t+2$, on a $x_{t+2} = \epsilon_{t+2} + \theta_1 \epsilon_{t+1}$
- En t , ϵ_{t+1} et ϵ_{t+2} sont inconnus et remplacés par leur espérance
 $E(\epsilon_{t+1}) = 0$
- On en déduit la prévision en t de x_{t+2} :

$$x_t^a(2) = 0$$

- L'erreur de prévision est : $e_t(2) = x_{t+2} - x_t^a(2) = (\epsilon_{t+2} + \theta_1 \epsilon_{t+1})$.
- L'erreur de prévision est nulle en moyenne, le prédicteur est sans biais.
- La variance de l'erreur de prévision est :
 $V(e_t(2)) = V(\epsilon_{t+2} + \theta_1 \epsilon_{t+1}) = \sigma_\epsilon^2(1 + \theta_1^2)$
- La variance de l'erreur de prévision s'accroît avec l'horizon de la

Généralisation à un $MA(q)$

- On a $x_t^a(h) = 0$ dès que $h > 1$ pour un processus $MA(1)$.
- Cette propriété se généralise à tout processus $MA(q)$. On a $x_t^a(h) = 0$ dès que $h > q$

Prévision ponctuelle l'horizon $h=1$ le cas d'un ARMA(p,q)

- Application des principes vus dans le cas d'un AR(p) et d'un MA(q).
- Exemple d'un ARMA(1,1) stationnaire

$$x_t = \phi_1 x_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1}$$

- Prévision à l'horizon $h = 1$
- $x_{t+1} = \phi_1 x_t + \epsilon_{t+1} + \theta_1 \epsilon_t \Rightarrow x_t^a(1) = \phi_1 x_t + \theta_1 \epsilon_t$
- L'erreur de prévision à l'horizon $h=1$ est donc $e_t(1) = \epsilon_{t+1}$.
- $E(e_t(1)) = 0$ et le prédicteur $x_t^a(1)$ est sans biais.
- La variance de l'erreur de prévision est $V(e_t(1)) = \sigma_\epsilon^2$

Prévision d'un ARMA(1,1) à l'horizon $h=2$

- $x_{t+2} = \phi_1 x_{t+1} + \epsilon_{t+2} + \theta_1 \epsilon_{t+1}$
- D'où : $x_t^a(2) = \phi_1 x_t^a(1) = \phi_1^2 x_t + \phi_1 \theta_1 \epsilon_t$
- L'erreur de prévision à l'horizon $h=2$ est :

$$\begin{aligned}
 e_t(2) &= x_{t+2} - x_t^a(2) \\
 &= (\phi_1 x_{t+1} + \epsilon_{t+2} + \theta_1 \epsilon_{t+1}) - \phi_1 x_t^a(1) \\
 &= \phi_1 (x_{t+1} - x_t^a(1)) + \epsilon_{t+2} + \theta_1 \epsilon_{t+1} \\
 &= \phi_1 \epsilon_{t+1} + \epsilon_{t+2} + \theta_1 \epsilon_{t+1}
 \end{aligned}$$

- L'erreur de prévision est nulle en moyenne.
- La variance de l'erreur de prévision est

$$V(e_t(2)) = \sigma_\epsilon^2 (1 + (\theta_1 + \phi_1)^2)$$

Prévision d'un ARMA(1,1)

- $x_t^a(2)$ est une prévision dynamique.
- La prévision statique est $x_{t+1}^a(1) = \phi_1 x_t + \theta_1 \epsilon_t$ dans le cas de x_{t+2} .
- pour $h > 1$, on aura $x_t^a(h) = \phi_1 x_t^a(h-1)$
- pour $h > 1$, la composante MA n'apporte plus d'information au calcul de la prévision, dans le cas d'un processus ARMA(1,1)
- Se généralise à un ARMA(p,q)

- La prévision est calculée pour la variable stationnarisée
- Recoloration = calcul de la prévision pour la variable initiale non stationnarisé
- Cas d'un processus DS : $x_t = \Delta z_t$
 - La prévision en t de z_{t+1} sera : $z_t^a(1) = z_t + x_t^a(1) = z_t + \Delta_t^a z_t(1)$.
 - Pour les horizons de prévision $h > 1$, on aura

$$z_t^a(h) = z_t^a(h-1) + x_t^a(h) = z_t + \Delta_t^a z_t(h)$$
- Cas d'un processus TS
 - $z_t = a + bt + x_t$ le processus TS
 - Le processus stationnarisé x_t est modélisé à l'aide d'un modèle ARMA.
 - La prévision en t de z_{t+h} sera : $z_t^a(h) = a + b(t+h) + x_t^a(h), \forall h > 0$.

- La prévision est un intervalle de confiance
- Prend en compte la précision de la prévision
- Hypothèse sur ϵ_t : $\epsilon_t \sim N(0, \sigma_\epsilon^2)$
- $e_t(1) = \epsilon_{t+1}$. Il en résulte que $e_t(1) \sim N(0, \sigma_\epsilon^2) \Rightarrow \frac{e_t(1)}{\sigma_\epsilon}$
- expression d'un intervalle de confiance à 95% pour les prévisions à l'horizon $h=1$:

$$\begin{aligned}
 & P \left[-2 \leq \frac{e_t(1)}{\sigma_\epsilon} \leq 2 \right] \\
 \Rightarrow & P \left[-2\sigma_\epsilon \leq x_{t+1} - x_t^a(1) \leq 2\sigma_\epsilon \right] \\
 \Rightarrow & P \left[x_t^a(1) - 2\sigma_\epsilon \leq x_{t+1} \leq x_t^a(1) + 2\sigma_\epsilon \right]
 \end{aligned}$$

- Prévision par intervalle de confiance à l'horizon h
- $e_t(h) = x_{t+h} - x_t^a(h) \sim N(0, \sigma^2(h))$
- Expression d'un intervalle de confiance à 95% pour la prévision est :

$$[x_t^a(h) - 2\sigma(h) \leq x_{t+1} \leq x_t^a(h) + 2\sigma(h)]$$

- $\sigma(h)$ est l'écart type de l'erreur de prévision à l'horizon h .
- $\sigma(h)$ diffère selon le modèle utilisé pour calculer les prévisions.

- Si l'on veut faire de la prévision dynamique sous **Gretl**, on doit modifier l'échantillon des observations. On décide de supprimer les 5 dernières observations.




Figure – Représentation des prévisions dynamiques

Prévisions statiques

- On choisit maintenant de faire des **prévisions statiques**.




Figure – Représentation graphique des prévisions statiques

- Comme **la qualité de la régression** n'est pas très grande, les prévisions ne sont pas très proches des valeurs réalisées.

- Possibilité de plusieurs modèles valides pour une seule série
- Utilisation de critères de sélection
- Les critères standards :
- Fondés sur l'erreur de prévision à l'horizon $h=1$.
- Le meilleur modèle est celui qui minimise le critère de sélection choisi.
 - Erreur absolue moyenne : $MAE = \frac{1}{T} \sum_{t=1}^T |\hat{\epsilon}_t|$
 - Erreur quadratique moyenne : $MSE = \frac{1}{T} \sum_{t=1}^T \hat{\epsilon}_t^2$
 - RMSE (root mean square error) qui est l'écart type estimé de l'erreur de prévision : $RMSE = \sqrt{MSE}$

- Les critères d'information les plus utilisés
- Le critère d'information de Akaike (1969) :
$$AIC(p, q) = \ln(\hat{\sigma}_{\hat{\epsilon}}^2) + \frac{2(p+q)}{T}$$
- Le critère d'information BIC ou de Schwarz (1978) :
$$BIC(p, q) = SC(p, q) = \ln(\hat{\sigma}_{\hat{\epsilon}}^2) + (p + q) \frac{\ln(T)}{T}$$
- Le critère d'information de Hannan et Quinn (1979) :
$$HQ(p, q) = \ln(\hat{\sigma}_{\hat{\epsilon}}^2) + (p + q) \frac{2\ln(\ln(T))}{T}$$
- Ces critères d'information représentent un arbitrage entre la précision du modèle et le nombre de paramètres à estimer.
- Le meilleur modèle est celui qui minimise le critère d'information retenu.

Propriétés des critères d'information

- quand ils sont appliqués à des $AR(p)$:
- le critère AIC surestime l'ordre de l' AR
- le critère HQ estime l'ordre de l' AR de façon convergente
- le critère SC est convergent de façon presque sure
- si $T \geq 16$, on a $\hat{p}(SC) \leq \hat{p}(HQ) \leq \hat{p}(AIC)$